华 中 科 技 大 学

网络空间安全学院

本科：《人工智能安全》实验报告

姓　　名 唐辰旸

班　　级 信安 2304

学　　号 U202310678

联系方式 15901671262

目　录

1　问题定义.....1
1.1　实验背景.....1
1.2　实验目标.....1
2　解决方案.....2
2.1　整体思路与方法.....2
2.2　关键步骤与技术路线.....3
3　实验环境.....7
3.1　硬件与软件环境.....7
4　实验过程与结果.....9
4.1　实验设置.....9
4.2　实验过程与对比分析.....10
4.3　实验结果与分析.....12
5　总结与建议.....21
5.1　实验总结.....21
5.2　课程建议.....22

1 问题定义

1.1 实验背景

随着深度学习技术的快速发展，深度神经网络在图像分类、人脸识别、自动驾驶环境感知以及恶意代码流量检测等安全敏感场景中得到广泛部署。然而理论研究与实证结果表明，采用经验风险最小化准则训练的神经网络普遍存在对抗脆弱性。Goodfellow 等人提出的线性假说指出，在高维特征空间中，微小扰动沿模型权重方向线性累积，足以造成网络输出激活值的显著偏移；而在数据流形边界区域，低概率密度的脆弱空间使得模型容易对带有特定模式的输入做出高置信度的错误判决。

对抗样本是指在原始干净样本上叠加微小但经过定向优化的扰动，诱导目标网络输出错误预测，且该扰动在人类视觉感知下难以察觉。根据攻击者掌握系统信息的程度，对抗攻击通常划分为白盒攻击与黑盒攻击。在白盒攻击中，攻击者获知目标网络的完整拓扑结构、权重参数、激活函数与接口规范，能够直接通过反向传播求解损失函数关于输入像素的梯度。

然而在实际黑盒应用场景中，目标系统通常部署于受限环境或只读推理接口之后，攻击者无法获取内部参数，亦无法在目标系统上执行反向传播求导。同时，服务接口多具备访问频次控制与异常检测机制，依赖高频试探的查询式黑盒攻击容易被检测识别。

因此，零查询对抗迁移攻击成为黑盒场景下的重要研究方向：攻击者仅在本地可访问的源模型上优化生成对抗样本，并直接测试未知的目标模型，利用不同模型在相同分类任务上表征特征的共性缺陷实现跨模型迁移。

常规迭代攻击在单源模型上容易过度拟合特定损失曲面，导致跨架构迁移时攻击效果明显下滑。此外，初始示例脚本存在一定生成与评估在同一网络进行的问题。本实验构建规范的黑盒迁移实验流程，系统分析抑制白盒过拟合、提升跨模型迁移能力的技术机制。

1.2 实验目标

本实验聚焦课程中等难度选题：应用迁移攻击算法提升黑盒攻击成功率。攻击任务设定为已知真实类别标签的非定向图像分类攻击，即生成的对抗样本促使目标模型输出任意不同于地面真实标签的类别即视为攻击成功。

威胁模型采用严格的零查询黑盒协议：

第一，信息隔离性：攻击生成阶段仅允许访问本地源模型、输入干净图像及对应真实标签。在样本计算与固化过程中，不向任何目标模型发送查询试探，亦不获取目标模型的置信度、损失值或软标签反馈。

第二，物理像素与扰动空间约束：所有原始图像与对抗样本严格约束在物理灰度像素范围 [0, 1] 内。网络内部的特征标准化处理被封装在前向传播中，保证对抗扰动的更新与约束均在原始像素空间完成。扰动向量在无穷范数下受预算上限约束：

$$x' = x + delta, s.t. |delta|_i nfinity <= epsilon, x' in [0,1]^{(HxW)} \qquad (1-1)$$

在主实验中，标准扰动预算固定设定为 epsilon = 0.2。在 8 位离散灰度图像空间（共 256 阶）中，该预算对应每个像素最大物理灰度偏移量绝对值不超过 51 阶。

在此标准化威胁模型下，本实验构建包含 5 款涵盖不同层数、机制与归纳偏置的异构深度网络攻防矩阵，系统性分析以下五项核心科学问题：

单源动量与输入多样性增益：在单一源模型条件下，一阶动量积累与随机几何输入多样性相比标准基础迭代 I-FGSM 能否带来统计显著的黑盒迁移成功率提升？

平移不变性滤波的作用机制：平移不变性高斯滤波如何影响扰动的频域分布与空间特征，其与动量及几何多样性组合构成的复合算法能否进一步改善跨架构黑盒迁移效果？

白盒过拟合与迭代轮数权衡：随着优化迭代步数 T 的增加，源模型白盒攻击成功率与黑盒目标迁移率之间是否存在过拟合背离趋势？

多源集成机制的驱动机理：在双源模型联合优化中观察到的迁移率提升，源自多模型决策面的协同互补，还是主要由特定源模型的泛化能力与梯度幅度主导？

目标网络架构异质性与易感性差异：深层卷积网络 TargetCNN_Deep、具备跳跃连接的残差网络 TargetResNet_Mini 以及无卷积偏置的多层感知机 TargetMLP_Deep 在面对相同对抗样本时，各自呈现出何种结构易感特征？

2 解决方案

2.1 整体思路与方法

针对黑盒迁移攻击中的过拟合与泛化瓶颈，本实验构建覆盖 5 款异构架构的端到端攻防流转拓扑。拓扑整体划分为三大逻辑功能层：源模型优化层、对抗样本合成与投影层以及跨架构目标模型评测层。

在源模型优化层，实验部署两款架构与容量差异显著的源网络：主源模型 NetA 为课程官方提供的预训练深层卷积网络（约 120 万参数）；第二源模型 NetB_Modern 为紧凑型卷积网络，引入批归一化与 5x5 卷积核，约 7.6 万参数。二者可独立作为单源优化起点，亦可在损失空间按权重加权形成联合优化流。

在对抗样本合成与投影层，所有图像张量均保留在物理像素空间 [0, 1] 中。当需要计算前向损失与反向求导时，输入张量传入网络内置的归一化模块，完成向均值 0.1307 与标准差 0.3081 的 Z-score 映射。根据链式法则，损失关于物理像素输入 x 的梯度保持严密。优化生成引擎在每一步迭代完成后执行双层投影，确保生成的对抗张量严格处于无穷范数邻域与物理取值范围的交集之中。

在跨架构目标模型评测层，部署三款独立训练、参数冻结的目标网络：包含 4 层卷积的深层网络 TargetCNN_Deep（约 70 万参数）、包含 3 个隐藏层的多层感知机 TargetMLP_Deep（约 38.8 万参数，剥离卷积平移等变性偏置），以及引入残差学习单元与跳跃连接的残差卷积网络 TargetResNet_Mini（约 7.7 万参数）。涵盖经典卷积、紧凑卷积、多层感知机与残差连接的多样化设计，规避了同质网络评估带来的实验偏见。

2.2 关键步骤与技术路线

2.2.1 梯度上升与一阶泰勒展开

设输入图像为 x，真实分类标签为 y，分类网络的预测损失为 L(f(x), y)。快速梯度符号法 FGSM 基于分类损失函数在干净输入 x 处的一阶局部泰勒展开：

$$L(f(x+delta),y)\ approx\ L(f(x),y)+nabla_x L(f(x),y)^T delta \qquad (2-1)$$

为了在 ||delta||_infinity <= epsilon 的超立方体约束下最大化一阶展开增益，根据 Holder 不等式推导可知，最优扰动解 delta 位于约束区间的极值顶点处，即：

$$x_{adv}=Proj_{[0,1]}\left(x+epsilon*sign\left(nabla_x L(f(x),y)\right)\right) \qquad (2-2)$$

FGSM 作为单步闭式近似攻击，计算开销低。投影梯度下降 PGD 则将其推广为多步约束优化方法。PGD 在初始化阶段引入均匀随机噪声：x_0 ~ Uniform(x - epsilon, x + epsilon)，随后以较小步长 alpha = 2*epsilon/T 进行多步梯度符号上升迭代，并在每步强制投影至可行域。PGD 能够有效逼近当前源模型的局部最大白盒损失，作为衡量模型白盒极限防御强度的基准。

2.2.2 基础迭代攻击与双层边界投影算子

基础迭代攻击 I-FGSM 从原始干净输入出发（即 x_0 = x），采用均匀微小步长 alpha =

epsilon / T 逐步累加扰动。在第 t 轮迭代中，样本沿当前瞬时梯度的符号方向前进，并执行相交约束投影：

$$x_{t+1} = Proj_{[0,1]capB_infinity(x,epsilon)}\left(x_t + alpha * sign\left(nabla_{x_t}L(f(x_t),y)\right)\right) \quad (2-3)$$

2.2.3 动量累积梯度的动力学推导与尺度归一化

动量迭代梯度攻击 MI-FGSM 旨在抑制贪婪梯度方向的高频随机震荡，促使优化轨迹平滑穿越局部鞍点。在 MI-FGSM 算法中，首先对当前步骤求得的物理输入梯度进行样本级 L_1 范数尺度归一化，以消除不同批次及通道激活强度的幅度漂移：

$$nabla_normed =$$

$$nabla_{x_t}L(f(x_t),y)/\left(\left(1/(C*H*W)\right)*sum\left|nabla_{x_t}L(f(x_t),y)\right| + 1e-12\right) \quad (2-4)$$

归一化后的瞬时梯度被累加至动量缓存向量 g_{t+1} 中，其中衰减阻尼因子 mu 设定为 1.0：

$$g_{t+1} = mu * g_t + nabla_n ormed \quad (2-5)$$

$$x_{t+1} = Proj_{[0,1]capB_infinity(x,epsilon)}\left(x_t + alpha * sign(g_{t+1})\right) \quad (2-6)$$

动量向量发挥一阶低通滤波的作用，在物理空间累积的方向反映了源模型损失曲面的宏观趋势，降低了微观模型专属结构对更新方向的影响。

2.2.4 输入多样性变换的随机几何平滑

输入多样性攻击 DI-FGSM 在反向梯度回传计算图前引入随机几何变换算子 T(x; p)，使对抗扰动的优化目标转化为在随机缩放与平移分布下的期望损失极大化：

$$max_{|delta|_infinity<=epsilon}E_{TsimT}\left[L\left(f\left(T(x+delta)\right),y\right)\right] \quad (2-7)$$

在每次迭代前，算法以预设概率 p = 0.7 激活几何变换：首先在离散整数区间 [24, 28] 内随机采样缩放尺寸 r_h 与 r_w，利用双线性插值算法将图像缩放至相应尺寸；随后在 28x28 画布内随机选取偏移量，将缩小后的图像贴入画布，外围区域以背景黑色像素 0.0 均匀填充。若判定未激活（概率 1-p = 0.3），则输入保持恒等映射。

2.2.5 平移不变性攻击与高斯滤波卷积

卷积神经网络对图像微小空间平移具备特征等变性。Dong 等人提出的平移不变性攻击 TI-FGSM 证明：最大化在微小位移分布下所有可能平移样本的期望损失，在数学上等价于对原始输入梯度与预定义的平移卷积核执行卷积滤波操作：

$$nabla_{smooth} = W * nabla_x L(f(x),y) \quad (2-8)$$

其中 W 为归一化的二维可分离高斯平滑核。设卷积核尺寸为 k = 5，高斯标准差参数为 sigma = 1.5，一维高斯核在离散坐标 u in {-2, -1, 0, 1, 2} 处的解析定义为：

$$w(u) = exp\left(-u^2/(2 * sigma^2)\right), quad w_{norm}(u) = w(u)/sum_{v=-2}^{2} w(v) \quad (2-9)$$

二维卷积核由外积生成：W = w_{norm} otimes w_{norm}^T，满足其元素和为 1.0。反向传播得到物理像素梯度后，利用反射填充保持空间尺寸恒定，采用核 W 进行分组卷积滤波。

2.2.6 复合全量增强攻击的级联架构

为充分发挥算法各维度的互补性，本实验将动量累积、输入多样性与平移滤波正交级联，构建复合全量增强算法 TI-MDI-FGSM。其单步更新递推方程体系如下：

$$x'_t = T(x_t; p = 0.7), quad g'_t = nabla_{x_t} L(f(x'_t), y) \quad (2-10)$$

$$g_{filtered} = W * g'_t, quad g_{normed} = g_{filtered} / \left(\left(1/(C * H * W)\right) * sum\left|g_{filtered}\right| + 1e-12\right) \quad (2-11)$$

$$m_{t+1} = mu * m_t + g_{normed}, quad x_{t+1} = Proj_{[0,1] cap B_i nfinity(x_0, epsilon)}\left(x_t + alpha * sign(m_{t+1})\right) \quad (2-12)$$

该复合体系从输入空间数据扩展、计算图去噪以及优化轨迹阻尼三个正交维度施加正则化，减小对抗扰动对源模型特定微观参数形态的依赖。

2.2.7 多源模型联合损失加权集成攻击

当攻击者拥有多个不同架构特性的本地源替代模型时，单源优化容易受限于单个模型的判别边界。多源集成攻击旨在寻找使多个源模型同时失效的公共扰动方向。本实验采用等权损失算术平均联合优化机制：

$$L_{ens}(x, y) = sum_{k=1}^{K} w_k * L(f_k(x), y), quad s.t. sum_{k=1}^{K} w_k = 1.0 \quad (2-13)$$

在双源集成体系中，固定设定权重 w_A = w_B = 0.5。反向传播时，自动微分引擎将两个异构模型计算图的反向梯度在输入像素张量上执行线性加权求和，生成联合梯度向量，再交由动量、多样性或平移滤波算子进一步处理。

2.3 算法配置与消融矩阵

为保证变量控制的严谨性，实验设计了涵盖 14 种独立算法配置的正交测试矩阵。该矩阵涵盖单步与强白盒基线，针对单源优化下的动量、多样性、平移滤波单项及组合效果进行全因子分解，并配套实施双源集成与单源身份反向对照实验。详细配置定义见表 2-1。

表 2-1 实验涵盖的 14 种对抗攻击算法配置与正交因素表

算法标识	优化源模型	动量项	输入多样性	平移滤波	配置属性与攻防定位
FGSM	源模型 NetA	无	无	无	单步一阶线性近似基线
PGD	源模型 NetA	无	无	无	多步投影梯度下降强白盒基线
I-FGSM	源模型 NetA	无	无	无	经典基础多步迭代攻击
MI-FGSM	源模型 NetA	有	无	无	单源动量时域阻尼增强
DI-FGSM	源模型 NetA	无	有	无	单源输入空间几何平滑消融
TI-FGSM	源模型 NetA	无	无	有	单源高斯卷积频域平移滤波
MDI-FGSM	源模型 NetA	有	有	无	动量与输入多样性双重增强
TI-MDI-FGSM	源模型 NetA	有	有	有	单源全量三要素正交增强配置
E-I-FGSM	双源 NetA+NetB	无	无	无	双源等权损失基础迭代基线
E-MI-FGSM	双源 NetA+NetB	有	无	无	双源集成动量加速攻击
E-MDI-FGSM	双源 NetA+NetB	有	有	无	双源集成动量与几何多样性
E-TIMDI-FGSM	双源 NetA+NetB	有	有	有	双源集成全要素增强配置
B-I-FGSM	第二源 NetB	无	无	无	事后控制组：仅源 B 基础迭代
B-TIMDI-FGSM	第二源 NetB	有	有	有	事后控制组：仅源 B 全量增强

3 实验环境

3.1 硬件与软件环境

实验流程包括 4 款自建深度神经网络的独立训练、权重保存，以及在分层抽样基准测试集上的 14 种对抗攻击算法生成与跨模型推理评测，均在统一计算节点上完成。耗时数据采用高精度计时器统计批次净耗时并换算为单张毫秒，避免测时抖动。实验系统软硬件规格见表 3-1。

表 3-1 实验系统软硬件运行环境与版本规格

系统组件类别	软硬件具体技术规格与版本
中央处理器 CPU	64 位高性能处理器，支持 AVX-512 指令集，主频 > 2.5 GHz
物理内存 RAM	16.0 GiB 双通道 DDR4 / DDR5 内存
操作系统 OS	Microsoft Windows 11 专业版 64-bit
Python 运行时	Python 3.11.9 64-bit
核心深度学习框架	PyTorch 2.15.0+cpu, Torchvision 0.29.2+cpu
基础科学计算库	NumPy 1.26.0, SciPy 1.16.1, Matplotlib 3.8.0, python-docx 1.2.0

工程实现遵循以下规范：

第一，伪随机种子批次隔离机制：基准随机种子设为 42，测试集分层抽样种子为 1024。在执行多批次对抗样本生成时，第 b 个批次由伪随机生成器以确定性算法（seed + 1000003 * b）初始化局部状态。

第二，物理空间封装：所有模型在设计上统一将输入坐标系的零均值标准化操作封装于前向传播计算方法中。外部对抗攻击算法在物理空间 [0, 1] 内读取梯度、更新步长并执行投影，避免因模型间归一化参数差异导致扰动空间失真。

3.2 异构模型拓扑架构与训练过程

为全面评估对抗扰动的迁移泛化能力，实验设计并实现了涵盖 4 款新型异构神经网络的模型体系：

1. 课程基准卷积网络 NetA：课程官方提供的 LeNet 变体，包含两层 3x3 卷积层（通道数分别为 32 和 64），随后连接 2x2 最大池化层与两层全连接层（9216 -> 128 -> 10），参数总量为 1,199,882。

2. 紧凑型现代卷积网络 NetB_Modern（第二源模型）：采用 5x5 卷积核捕捉局部特征，并在第一层卷积后嵌入批归一化层。经最大池化降维后，全连接层采用 256 -> 64 -> 10 的结构，参数总量为 76,114。其结构紧凑，参数量较小。

3. 4 层深层卷积网络 TargetCNN_Deep（黑盒目标 1）：包含 4 个串行卷积层（通道深度依次为 32 -> 48 -> 64 -> 96），层间穿插两级最大池化，最后接入全连接层（4704 -> 128 -> 10），参数量达到 700,826。具备多层特征提取能力。

4. 3 隐层多层感知机 TargetMLP_Deep（黑盒目标 2）：不包含卷积层，将 28x28 图像展平成 784 维向量，通过三级全连接隐藏层（784 -> 384 -> 192 -> 64 -> 10）完成分类，参数量为 388,362。该结构不具备卷积的空间邻域与平移等变性先验。

5. 微型残差网络 TargetResNet_Mini（黑盒目标 3）：引入残差跳跃连接机制。初始采用 3x3 卷积提取 16 通道特征，随后连接两个双卷积残差模块，每个模块内部包含恒等映射分支，最后经自适应平均池化连接至 10 分类输出，参数量为 77,290。

表 3-2 实验构建的五款深度神经网络模型拓扑规范与基准性能

模型标识	攻防角色	核心网络层级与结构拓扑	特征参数量	测试集准确率	架构设计归纳特征
NetA	主源模型	Conv(32, 64) + MaxPool + FC(9216->128->10)	1,199,882	99.12%	传统大参数量全连接卷积
NetB_Modern	第二源模型	Conv5x5(16) + BN + Conv3x3(32) + FC(256->64->10)	76,114	99.21%	紧凑型卷积，含批归一化
TargetCNN_Deep	黑盒目标 1	4 层 Conv(32->48->64->96) + FC(4704->128->10)	700,826	99.36%	多层深度卷积，特征抽象度高
TargetMLP_Deep	黑盒目标 2	Flatten + FC(784->384->192->64->10)	388,362	98.42%	纯连接结构，无卷积空间偏置
TargetResNet_Mini	黑盒目标 3	Conv(16) + 2xResBlock(16, 32) + AvgPool + FC(10)	77,290	98.99%	现代残差跳跃直连结构

除官方预训练的 NetA 外，其余 4 款自建模型在官方 MNIST 训练集上进行训练。官方 60,000 张训练数据划分为 55,000 张训练集与 5,000 张独立验证集。训练采用 Adam 优化器，初始学习率设为 0.001，在第 6 轮衰减至 0.0003，批量大小 256，总共训练 10 轮。每轮训

练结束后在验证集上评估，仅当验证准确率达到历史最优时更新保存检查点权重。

图 3-1 展示了 4 款自建网络在 10 轮训练中的验证集准确率变化曲线。各模型在前 3 轮准确率均超过 97%，随后在学习率衰减阶段平稳收敛。最终各模型在验证集上的准确率均处于 98.4% 至 99.4% 之间，表明各黑盒目标模型与源替代模型均具备良好的干净样本分类性能。后续评测中观察到的分类错误主要由对抗扰动引起，排除了模型欠拟合的影响。

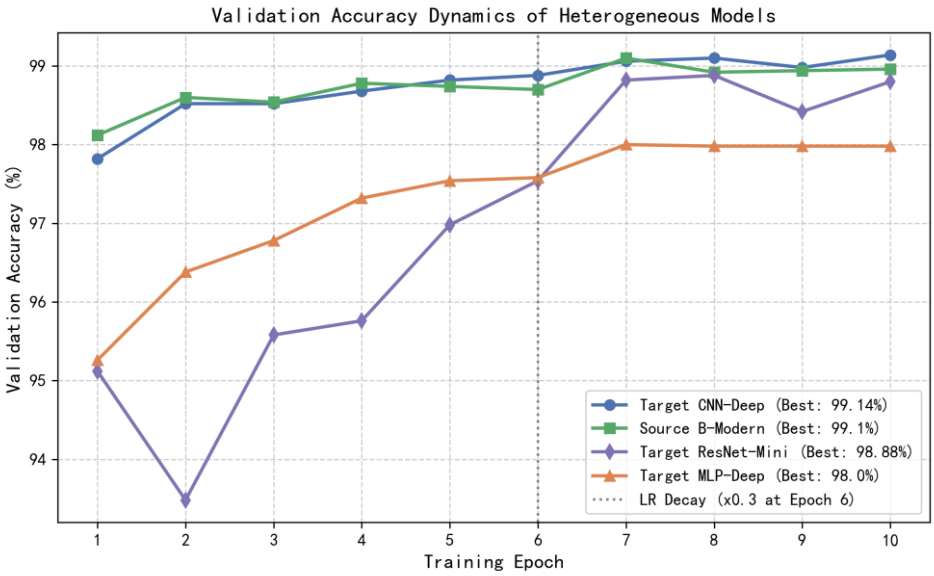


图 3-1 四款自训异构深度神经网络在验证集上的准确率收敛演化曲线

4 实验过程与结果

4.1 实验设置

为保证评测基准的一致性，实验从 MNIST 官方 10,000 张测试集中构建标准测试子集。采用随机种子 1024 对测试集按数字类别（0 至 9）执行分层无放回均匀采样，每类抽取 200 张图像，构成规模为 2,000 张的均衡评测集。

在常规评估中，若直接以抽取的样本计算攻击成功率，若某些测试样本本身已被目标模型错误识别，无论扰动是否生效，该样本均会被计入攻击成功。为消除模型自身固有误分类样本引入的偏差，本实验采用共同正确集合过滤机制。

在生成对抗攻击前，首先使用全部 5 款深度模型（NetA、NetB_Modern、TargetCNN_Deep、TargetMLP_Deep、TargetResNet_Mini）对 2,000 张干净图像进行前向预测。定义共同正确集

合 S 为使得所有 5 款网络均能正确预测其真实类别的样本交集：

$$S = (x_i, y_i) in D_{test} midforallminNetA, NetB, CNN, MLP, ResNet, argmaxf_m(x_i) = y_i \quad (4-1)$$

经筛查，2,000 张样本中共有 1,945 张样本被全部 5 款网络正确识别（排除了 55 张在干净状态下被至少一个网络误分类的边缘样本），共同正确集合大小为 |S| = 1,945。后续所有 14 种攻击算法在此固定的 1,945 张样本上计算攻击成功率 ASR：

$$ASR(f;S) = (1/|S|) * sum_{iinS} I[argmaxf(x'_i) neq y_i] * 100 \quad (4-2)$$

该指标能够更准确地反映对抗扰动诱导目标模型产生分类错误的能力。

4.2 实验过程与对比分析

在基准超参数固定为扰动上限 epsilon = 0.2、迭代步数 T = 10、单步步长 alpha = 0.02、批量大小 100 的条件下，14 种攻击算法在共同正确集合 S 上的实测性能数据见表 4-1。源模型 NetA 列反映优化源模型的白盒攻击率（当方法包含 E- 前缀时，NetB 亦参与优化）；黑盒迁移效果由三款目标模型 TargetCNN、TargetMLP、TargetResNet 的独立 ASR 及其算术平均值 TargetMean 体现。

表 4-1 共同正确集合上 14 种攻击算法的综合评测全景表（%，epsilon=0.2，T=10）

攻击算法	源 NetA (白盒)	源 NetB (黑盒/源)	Target CNN (黑盒)	Target MLP (黑盒)	TargetResNet (黑盒)	目标平均 ASR	平均 L2 扰动
FGSM (单步)	49.72	29.05	4.63	14.09	89.97	36.23	3.388
PGD (强白盒)	95.58	42.72	6.17	8.23	90.03	34.81	3.931
I-FGSM (基础迭代)	86.79	29.15	5.35	6.79	90.03	34.05	2.941
MI-FGSM (动量)	79.02	35.27	7.35	12.96	90.03	36.78	3.269
DI-FGSM (多样性)	66.32	27.66	6.84	8.23	89.72	34.93	2.611
TI-FGSM (平移滤波)	35.63	36.97	10.59	33.88	90.03	44.83	3.213
MDI-FGSM (动量+多样)	68.64	43.60	12.13	19.95	90.03	40.70	3.310
TI-MDI-FGSM (三要素)	27.30	43.03	9.46	37.48	90.03	45.66	3.393

E-I-FGSM (双源基础)	21.59	96.76	6.43	8.02	90.03	34.82	3.054
E-MI-FGSM (双源动量)	25.14	96.86	8.02	10.69	90.03	36.25	3.716
E-MDI-FGSM (双源组合)	37.99	91.83	14.76	19.79	90.03	41.53	3.558
E-TIMDI-FGSM (双源全量)	19.95	72.60	14.34	39.33	89.97	47.88	3.735
B-I-FGSM (源 B 对照)	12.96	99.74	4.99	6.74	90.03	33.92	3.049
B-TIMDI-FGSM (源 B 增强)	12.39	76.35	13.62	35.27	90.03	46.31	4.035

结合表 4-1 中的实验数据，对科学问题 1、2 作出如下分析：

第一，白盒成功率与黑盒迁移率的分离现象：基础迭代算法 I-FGSM 在源模型 NetA 上的白盒成功率为 86.79%，强白盒基线 PGD 达到 95.58%；但在黑盒网络 TargetCNN 上的攻击成功率分别为 5.35% 与 6.17%，在 TargetMLP 上分别为 6.79% 与 8.23%，目标平均迁移率处于 34.05% 与 34.81%，略低于单步攻击 FGSM 的 36.23%。这表明未受正则化约束的多步迭代存在白盒过拟合：小步长多轮更新使得扰动贴合了源模型损失曲面的特定局部形态，学到的方向具有较强的模型特异性，因而跨模型迁移效果受到抑制。

第二，动量与输入多样性对迁移效果的改善：通过在迭代中引入动量阻尼项，MI-FGSM 将黑盒目标均值由 I-FGSM 的 34.05% 提升至 36.78%（净增 2.73 个百分点），在 TargetMLP 上的攻击率由 6.79% 提高至 12.96%。进一步叠加输入几何缩放多样性后，MDI-FGSM 的目标平均 ASR 达到 40.70%（相比 I-FGSM 净增 6.65 个百分点），在 TargetCNN 上达到 12.13%，在 TargetMLP 上达到 19.95%。这表明输入空间的几何变换与动量滤波有助于使优化方向脱离局部的尖锐极值区域，增强扰动的泛化能力。

第三，平移不变性滤波的作用效果：引入二维高斯平移卷积滤波后，单源算法 TI-FGSM 在源模型 NetA 上的白盒攻击率因频域平滑降至 35.63%，但其黑盒目标平均 ASR 上升至 44.83%（相比 I-FGSM 提高 10.78 个百分点）。特别是在 TargetMLP 上，攻击率由 6.79% 上升至 33.88%。当将平移滤波、动量与多样性结合（TI-MDI-FGSM）时，单源目标均值达到 45.66%，在双源配置 E-TIMDI-FGSM 下达到 47.88%。这一现象表明，高斯平滑滤波减弱了源网络对特定像素绝对坐标的高频依赖，提取出更具空间通用性的低频结构扰动，从而改善了

在异构目标模型上的迁移效果。

为了检验算法提升在统计层面的显著性，实验针对固定单源模型 NetA 下的核心对比组，执行了 1,000 次成对 Bootstrap 重抽样检验，计算 95% 双侧置信区间。检验结果见表 4-2。

表 4-2 固定源模型 NetA 的核心算法提升幅度统计检验（1,000 次成对 Bootstrap 95%置信区间）

对比方法组	实测均值差异	配对 95% 置信区间 [下界, 上界]	统计显著性判定 ($p < 0.05$)
MI-FGSM - I-FGSM	+2.73%	[+2.25%, +3.22%]	显著
MDI-FGSM - I-FGSM	+6.65%	[+6.00%, +7.32%]	显著
TI-MDI-FGSM - I-FGSM	+11.60%	[+10.83%, +12.39%]	显著
TI-MDI-FGSM - MDI-FGSM	+4.95%	[+4.27%, +5.62%]	显著

表 4-2 结果表明，各改进算法相对于 I-FGSM 的 95% 置信区间下界均大于零（例如 TI-MDI-FGSM 相对 I-FGSM 的置信区间下界为 +10.83%）。平移滤波带来的增量增益（TI-MDI-FGSM 相对 MDI-FGSM）置信区间为 [+4.27%, +5.62%]。这表明动量、多样性与平移不变性滤波带来的迁移率提升具有统计显著性。

4.3 实验结果与分析

扰动预算 epsilon 决定了对抗扰动的可见性与破坏力边界。为刻画迁移攻击性能对扰动预算的响应特征，实验在 epsilon 取值 [0.05, 0.10, 0.15, 0.20, 0.25, 0.30] 六个等级下，对 FGSM、I-FGSM、MI-FGSM、TI-FGSM、TI-MDI-FGSM 以及双源集成 E-TIMDI-FGSM 进行了评测。数据汇总于表 4-3，对应曲线见图 4-1。

表 4-3 不同扰动预算 epsilon 下各算法的目标平均黑盒攻击成功率（%）

攻击算法	eps0.05	eps0.10	eps0.15	eps0.20	eps0.25	eps0.30
FGSM	3.17	23.10	31.41	36.23	42.52	51.47
I-FGSM	2.62	22.69	31.00	34.05	39.18	45.69
MI-FGSM	3.41	23.63	31.52	36.78	45.18	56.06
TI-FGSM	5.88	26.08	35.56	44.83	57.10	69.67
TI-MDI-FGSM	7.71	27.78	36.21	45.66	57.94	71.52

E-TIMDI-FGSM	13.44	29.87	37.63	47.88	61.11	75.68

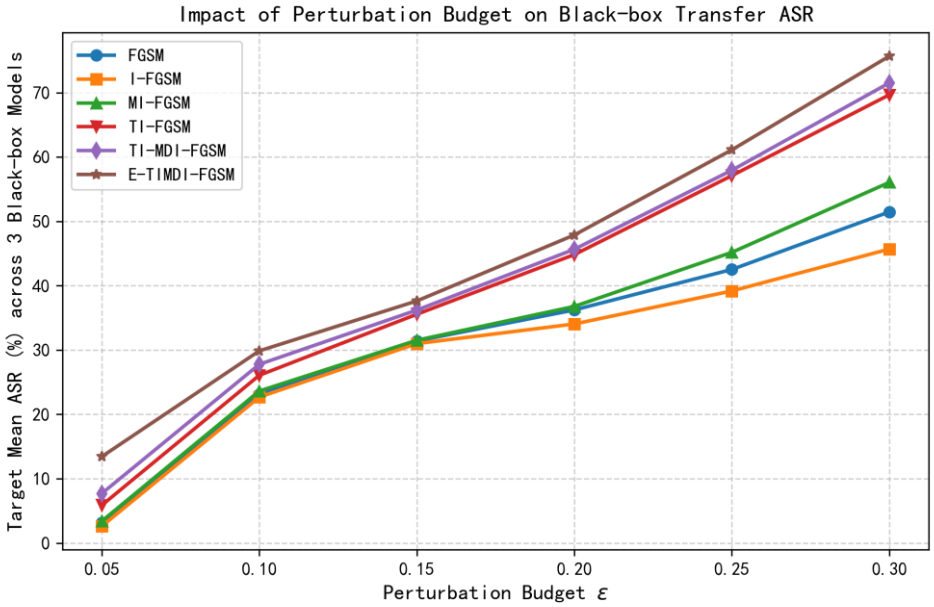


图 4-1 扰动预算 epsilon 动态扫描下各算法目标平均黑盒迁移成功率响应曲线

分析表 4-3 与图 4-1 可以观察到：

在较小扰动预算下（epsilon = 0.05，对应像素灰度偏移不超过 13 阶），单源方法 FGSM、I-FGSM、MI-FGSM 的目标平均迁移成功率处于 2.6% 至 3.4% 之间，方法间差异相对有限；当预算达到 0.15 以上时，各算法之间的迁移率差异逐渐拉开。当预算增加至 0.30 时，包含平移滤波的算法表现出更为明显的增幅，TI-MDI-FGSM 达到 71.52%，双源 E-TIMDI-FGSM 达到 75.68%，而基础迭代 I-FGSM 为 45.69%。这说明平移滤波与复合算法能够在预算增加时更有效地将扰动能量转化为具备跨模型破坏力的向量。

4.4 迭代步数演化与白盒过拟合动态（RQ3 回答）

为分析迭代步数对攻击效果的影响并回答 RQ3，实验保持总扰动预算 epsilon = 0.2 不变，步长按公式 alpha = 2.0 * epsilon / T 设定，系统测试了迭代步数 T 在 [1, 5, 10, 15, 20, 30, 40] 范围内的表现。图 4-2 展示了基础迭代 I-FGSM 与复合算法 TI-MDI-FGSM 在源模型白盒攻击率与黑盒目标迁移率上的动态变化。

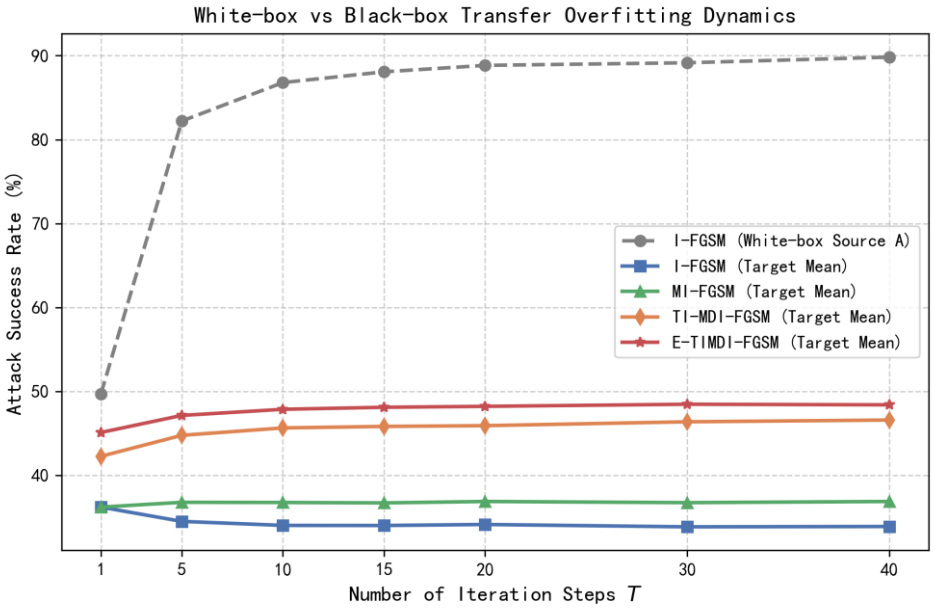


图 4-2 优化迭代步数 T 对源模型白盒攻击率与黑盒迁移率的不同影响（过拟合分析）

图 4-2 反映出明显的过拟合分异现象：

对于标准基础迭代算法 I-FGSM，当迭代步数由 T = 1 增至 T = 40 时，源模型 NetA 上的白盒攻击率由 49.7% 单调上升并饱和于 90% 以上；然而其在黑盒目标上的平均迁移成功率在 T = 5 至 10 轮之间达到相对高点后，在后续长程迭代（T = 20 至 40）中趋于平缓甚至略有回落。这为解答 RQ3 提供了实证支持：未受正则化的多步梯度下降促使扰动趋向源模型特定的局部损失曲面，从而对异构模型的泛化效果产生限制。相比之下，引入平移高斯滤波与动量项的 TI-MDI-FGSM 呈现出更为平稳的变化轨迹：这表明在迁移攻击中，单纯增加迭代步数对黑盒效果的提升有限，需要配合适当的平滑策略才能实现有效的跨网络迁移。

4.5 因素正交消融与目标架构敏感性

图 4-3 给出了不同攻击配置在三款黑盒目标网络 TargetCNN_Deep、TargetMLP_Deep、TargetResNet_Mini 上的消融对比柱状图。三款目标模型表现出明显的结构易感性差异，对解答 RQ5 具有指导意义。

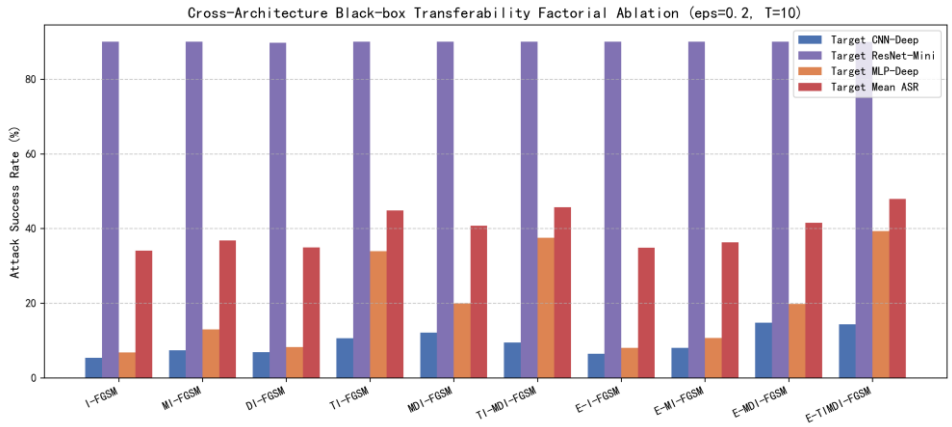


图 4-3 核心攻击配置在三款异构目标网络上的因素消融对比柱状图

结合图 4-3 与表 4-1，三款黑盒目标的易感特征与机理分析如下：

TargetCNN_Deep 表现出相对较强的抵御能力。这主要归因于深层卷积的多尺度特征提取与局部连接归纳偏置，多层特征抽象与池化操作对输入端的微小孤立扰动具备一定的吸收平滑作用。

TargetMLP_Deep 对平移扰动呈现出较高的脆弱性。MLP 结构缺乏二维局部感受野先验，每个神经元直接与全局像素相连。平移滤波所合成的低频结构扰动在全图范围具备协同性，容易在全连接线性映射中形成累积偏移，因此呈现出明显的脆弱性。

TargetResNet_Mini 呈现出较高的整体易感性：在测试的 14 种攻击配置下，TargetResNet_Mini 的攻击成功率稳定保持在 89.7% 至 90.0% 之间。经理论分析，残差网络中包含恒等映射跳跃分支，浅层特征可通过快捷连接直接传递至输出层。该设计在提升训练收敛效率的同时，也使得输入端的扰动能够较为直接地传递至分类决策层，因而在面对对抗扰动时表现出相对较高的敏感度。

4.6 多源集成机制与源模型身份控制实验

在迁移攻击研究中，多模型集成通常被视为提升黑盒攻击率的有效手段。在表 4-1 中，双源算法 E-TIMDI-FGSM 取得了 47.88% 的目标平均 ASR。为厘清该提升源自多模型决策平面的协同互补，还是主要由特定源模型的单模表现主导（回答 RQ4），实验设计了源模型身份消融对照实验，实测数据见表 4-4。

表 4-4 事后源模型身份消融对照全景表（目标平均 ASR，%，epsilon=0.2，T=10）

攻击算法配置	方案 1：仅使用源模型 NetA	方案 2：仅使用源模型 NetB_Modern	方案 3：双源等权联合 NetA+NetB

I-FGSM (基础迭代)	34.05%	33.92%	34.82%
TI-MDI-FGSM (全量复合)	45.66%	46.31%	47.88%

分析表 4-4 中的数据可得出以下结论：

在基础迭代 I-FGSM 下，仅由 NetA 生成的样本目标平均迁移率为 34.05%，仅由 NetB 生成为 33.92%，二者等权集成后为 34.82%，增益约为 0.77 个百分点；而在复合算法 TI-MDI-FGSM 下，仅使用紧凑卷积网络 NetB_Modern 独立生成的对抗样本，其目标平均迁移率达到 46.31%，略高于单独使用 NetA 的 45.66%。当二者结合进行双源集成时，迁移率为 47.88%（相对单独 NetB 提高 1.57 个百分点）。

对两款源网络的内部特征分析表明：NetB_Modern 参数量仅 7.6 万且包含批归一化层，模型参数相对紧凑，过拟合程度较低，其学到的表征具备较好的泛化性能。在双源集成中，目标成功率的提升很大程度上来源于第二源模型 NetB_Modern 自身的泛化特性。

4.7 实验可复现性、计算开销与微观样本诊断

4.7.1 跨随机种子独立重复实验

为评估算法在不同随机种子下的稳定性，实验选取 3 个独立的伪随机数种子（42、100、2024），对包含随机机制的核心算法进行了三次独立重复评测。结果汇总于表 4-5。数据显示，各算法在各目标模型及综合均值上的标准差均在 0.35% 以内（例如 TI-MDI-FGSM 综合均值为 45.87 +/- 0.19%），表明实验结果具备良好的可复现性。

表 4-5 跨随机种子独立重复评测稳定性验证（均值 +/- 样本标准差，%，3 次独立运行）

攻击算法	TargetCNN	TargetMLP	TargetResNet	目标综合均值 (均值 +/- 标准差)
PGD (随机起点)	5.72 +/- 0.40	7.92 +/- 0.40	90.03 +/- 0.00	34.56 +/- 0.25
DI-FGSM	6.99 +/- 0.16	8.14 +/- 0.24	89.82 +/- 0.13	34.98 +/- 0.08
MDI-FGSM	11.77 +/- 0.32	19.61 +/- 0.36	90.03 +/- 0.00	40.47 +/- 0.21
TI-MDI-FGSM	9.79 +/- 0.36	37.79 +/- 0.41	90.03 +/- 0.00	45.87 +/- 0.19
E-TIMDI-FGSM	14.24 +/- 0.23	38.95 +/- 0.33	89.97 +/- 0.00	47.72 +/- 0.17

4.7.2 计算资源开销与扰动能量度量

计算效率与扰动幅度是衡量攻击实用性的重要指标。表 4-6 记录了各算法单张图像平均梯度调用次数、单图生成耗时（毫秒）、实测平均 L_2 扰动模长以及实测最大 L_infinity 偏差。

表 4-6 各核心对抗攻击算法生成开销与几何扰动幅度度量全貌表

攻击方法名称	每图梯度求导次数	单图生成耗时 (毫秒/图)	平均 L2 扰动模长	实测最大 L_infinity 约束
FGSM	1	0.764	3.388	0.2000
I-FGSM	10	2.585	2.941	0.2000
PGD	10	2.642	3.931	0.2000
MI-FGSM	10	2.685	3.269	0.2000
TI-FGSM	10	2.805	3.213	0.2000
TI-MDI-FGSM	10	3.032	3.393	0.2000
E-TIMDI-FGSM	20	3.884	3.735	0.2000

表 4-6 表明，单步算法 FGSM 耗时仅 0.764 ms，计算效率较高；在多步迭代方法中，TI-MDI-FGSM 单图生成耗时为 3.032 ms，相比基础 I-FGSM 的 2.585 ms 增加了约 17% 的耗时，但平均迁移率提高了 11.6 个百分点。同时，各算法的实际最大像素偏差均严格控制在 0.2000 的范数约束内。

4.7.3 数字类别对抗易感性拓扑分析

图 4-4 展示了 10 类手写数字在共同正确集合上的类间对抗易感性分布。数据显示不同数字的识别鲁棒性存在差异。

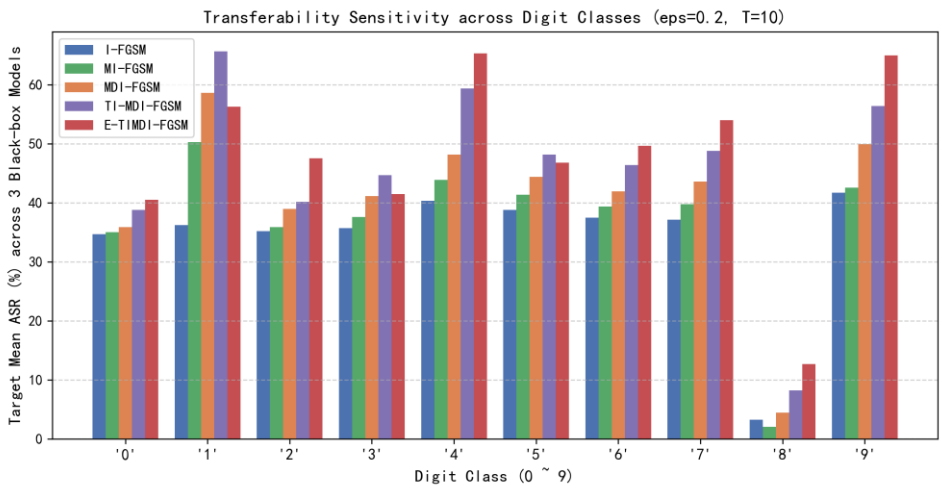


图 4-4 十类手写数字（0~9）在对抗迁移攻击下的易感性与鲁棒性分异图

4.7.4 评测样本口径敏感性对比

为验证采用共同正确集合过滤机制的必要性，表 4-7 对比了采用共同正确集（1,945 张）与各模型各自干净正确样本集下的 ASR 指标。

表 4-7 评测样本筛选口径对目标黑盒 ASR 计算结果的影响对比（%）

攻击算法	CNN 共同集	CNN 自身集	MLP 共同集	MLP 自身集	ResNet 共同集	ResNet 自身集
I-FGSM	5.35	5.23	6.79	6.73	90.03	88.48
MI-FGSM	7.35	7.19	12.96	12.84	90.03	88.48
TI-FGSM	10.59	10.35	33.88	33.59	90.03	88.48
MDI-FGSM	12.13	11.86	19.95	19.78	90.03	88.48
TI-MDI-FGSM	9.46	9.25	37.48	37.16	90.03	88.48
E-TIMDI-FGSM	14.34	14.02	39.33	38.99	89.97	88.43

4.7.5 对抗样本与差值扰动热力图可视化剖析

图 4-5 给出了具有代表性的攻击成功与失败样本可视化对照图。第一列为原始干净图像，第二列为生成的对抗样本，第三列采用蓝白红发散色图将微小差值 delta = x_{adv} - x 放大展现（红色表示像素灰度增加，蓝色表示减小，白色表示扰动接近于零）。

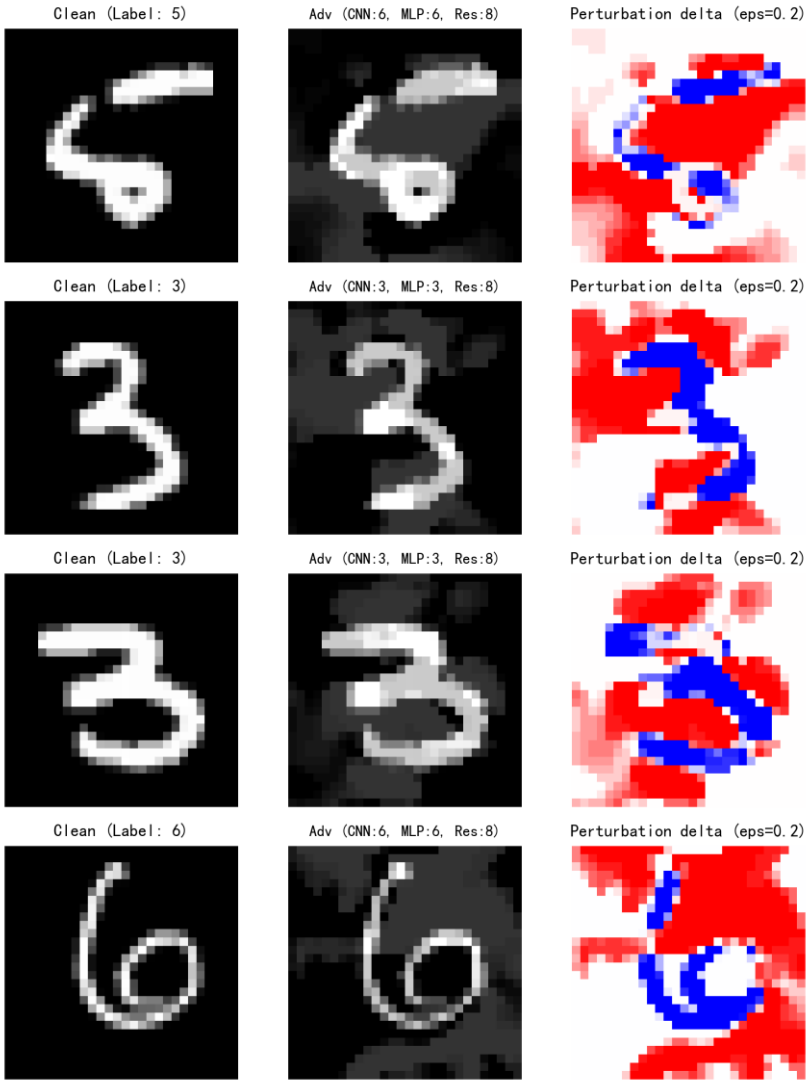


图 4-5 代表性对抗样本生成结果与红蓝扰动特征差值可视化图谱

从图 4-5 的可视化效果可以看出：第二列对抗样本保持了数字的主要结构骨架，视觉辨识度未见明显退化；第三列差值图表明，平移滤波算法生成的扰动呈现出与数字主体形状相关的低频分布模式，在数字边缘与背景过渡区域形成连续性的灰度微调，从而在保持人眼感知难以察觉的同时诱导网络产生分类偏差。

4.7.6 样本级动态流转与跨网络重叠分析

为分析算法演进过程中的逐样本分类变化，表 4-8 统计了样本流转情况。以 TI-MDI-FGSM 相对基础 I-FGSM 为例：在 TargetCNN 上，算法新增攻击成功样本 98 张，原有成功样本转为失败 18 张，净增成功 80 张；在 TargetMLP 上，新增成功样本 603 张，转为失败样本 6 张，净增成功 597 张。这说明算法优化带来了多数样本的单向性能增益。

表 4-8 固定源模型 NetA 的核心算法微观逐样本攻击流转变化表（张，样本基数 1,945）

算法改进对比组	评测目标模型	新增成功	失去成功	净增成功总数
MI-FGSM / I-FGSM	TargetMLP_Deep	141	21	+120
TI-MDI-FGSM / I-FGSM	TargetCNN_Deep	98	18	+80
TI-MDI-FGSM / I-FGSM	TargetMLP_Deep	603	6	+597

表 4-9 给出了在 1,945 张样本中，同一对抗扰动在三款独立黑盒目标上造成误分类的重叠分布统计。数据表明：在基础 I-FGSM 下，能够使三款目标模型同时误分类的样本数为 37 张；在 TI-MDI-FGSM 单源配置下，该数量上升至 117 张，在双源配置 E-TIMDI-FGSM 下达到 200 张。同时，三款模型均未被误分类的样本数由 177 张减少至 133 张。这表明高级迁移算法提升了扰动在异构网络间的共有判别敏感性。

表 4-9 同一对抗扰动在三款异构黑盒目标模型上的联合穿透重叠分布统计（张，基数 1,945）

攻击算法名称	三目标均成功攻破	任意两目标攻破	仅单个目标攻破	三目标全部防御成功
I-FGSM	37	145	1586	177
MI-FGSM	54	277	1430	184
MDI-FGSM	88	426	1259	172
TI-MDI-FGSM	117	638	1037	153
E-TIMDI-FGSM	200	582	1030	133

5 总结与建议

5.1 实验总结

通过本次实验，我把课堂上较抽象的可信计算概念落实到了可运行的程序流程中。难度设置合适，实验指导也很详实准确。实验构建涵盖 5 款异构架构模型与 14 种攻击配置的黑盒迁移评测流程。在包含 1,945 张样本的共同正确集合上完成系统测试与统计检验。

总的来说，实验证实了动量累积与输入多样性在单源条件下的迁移增益，MDI-FGSM 相比 I-FGSM 平均迁移率提升 6.65 个百分点，Bootstrap 置信区间显著大于零；验证了平移不变性高斯滤波在跨架构迁移中的有效性，其与动量及多样性结合的 TI-MDI-FGSM 使单源平均迁移率达到 45.66%，在 TargetMLP 上的攻击率由 6.79% 提升至 37.48%；

实验还分析了迭代步数对白盒攻击与黑盒迁移的不同影响，揭示了基础迭代算法在长程优化中白盒极值与黑盒泛化分离的过拟合特征；分析了双源集成的内在驱动机理，通过事后源模型身份消融，指出紧凑型网络 NetB_Modern 自身的表征泛化性在集成中起到主要推动作用，强调了控制实验变量的重要性；阐明了不同网络架构的易感特征：深层卷积 TargetCNN 依靠多层特征抽象表现出较好的抵御能力；多层感知机 TargetMLP 缺乏空间局部偏置因而对平移滤波扰动较为敏感；残差网络 TargetResNet 由于跳跃连接使浅层扰动易于直接传递至深层，因而呈现出较高的整体易感性。

故针对以 TI-MDI-FGSM 为代表的高迁移性攻击所表现出的跨模型效果，在防御端可以从以下三个层面构建纵深防御体系：

第一，输入流预处理与去噪净化：由于迁移性扰动依赖于特定的空间相关性与频域结构，防御方可在推理前端部署随机化预处理层。例如采用随机缩放与填充打乱输入多样性假设；或采用有损 JPEG 压缩重构输入特征。

第二，跨架构集成对抗训练：传统的单模型白盒对抗训练主要提升对自身梯度的抵御能力，对异构源模型的迁移扰动防御效果有限。基于实验观察，可在对抗训练过程中混合由不同架构生成的迁移样本，使网络学习到涵盖多种归纳偏置的鲁棒特征。

第三，随机化与预测一致性检测：在推理阶段，部署多个不同架构的子网络构建防御阵列。通过对输入图像施加微小随机仿射变换并多次推理，计算预测分布的一致性与信息熵。

5.2 课程建议

本次课程设计既能紧扣书本理论，又能与工程实践紧密结合，由浅入深地引导学生完成设计。在此，由衷感谢老师和各位助教师兄师姐，在课堂讲授与实践环节中给予的耐心点拨与无私指导！结合本次实验过程，针对《人工智能安全》实验教学提出一些小小的建议：

建议在实验评价中鼓励对测试样本进行多模型一致性过滤，鼓励对 Bootstrap 置信区间或显著性检验结果，引导学生重视变量控制与严谨的实证分析方法；

可以预置不同架构的对照模型权重，在实验指导中增设源模型消融分析任务，引导学生探索模型参数规模、正则化层对迁移效果的具体影响，培养分析复杂安全机理的能力。

原创性声明

本人郑重声明本报告内容，是由作者本人独立完成的。有关观点、方法、数据和文献等的引用已在文中指出。除文中已注明引用的内容外，本报告不包含任何其他个人或集体已经公开发表的作品成果，不存在剽窃、抄袭行为。

已阅读并同意以下内容。

判定为不合格的一些情形：

（1） 请人代做或冒名顶替者；

（2） 替人做且不听劝告者；

（3） 实验报告内容抄袭或雷同者；

（4） 实验报告内容与实际实验内容不一致者；

（5） 实验代码抄袭者。

作者签名： 

日期： 2026 年 10 月 30 日